# Analisi e Predizione del Tumore al Seno con Logistic Regression

Progetto di Machine Learning

Carlo C. | Luca R. | Elena L.

# Analisi Tumore al Seno

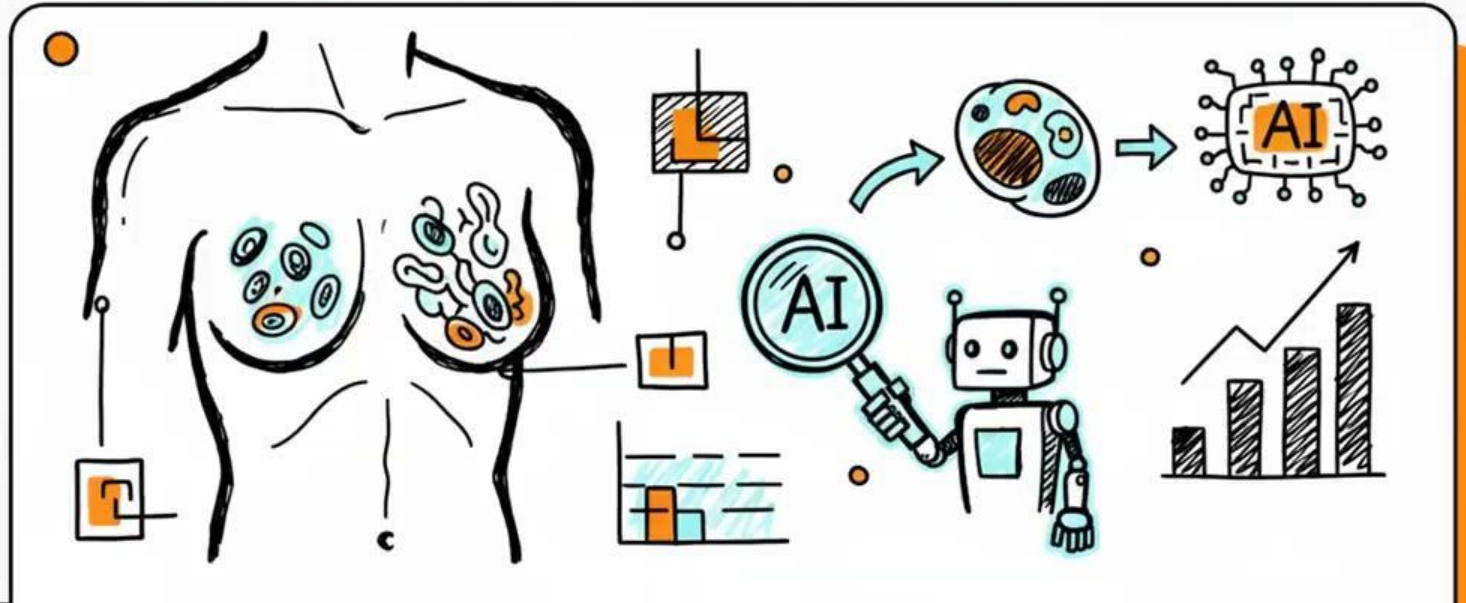

# Obiettivi del Progetto

- **Analizzare** i dati clinici di 569 pazienti affetti da tumore al seno (Wisconsin Breast Cancer Dataset)
- **Identificare** le variabili più rilevanti per la diagnosi differenziale tra benigno e maligno
- **Addestrare** un modello predittivo basato su Logistic Regression con alta accuratezza diagnostica
- **Valutare** le prestazioni del modello tramite metriche clinicamente rilevanti (AUC, Precision, Recall)

**Dati**

Raccolta e pulizia del dataset

**Analisi**

Esplorazione e feature selection

**Predizione**

Modellazione e valutazione

# Il Dataset: Wisconsin Breast Cancer

| Caratteristica | Dettaglio |
|---|---|
| Pazienti totali | **569** |
| Variabili numeriche | 30 feature |
| Classi target | Benigno (357) · Maligno (212) |
| Fonte | Wisconsin Breast Cancer |

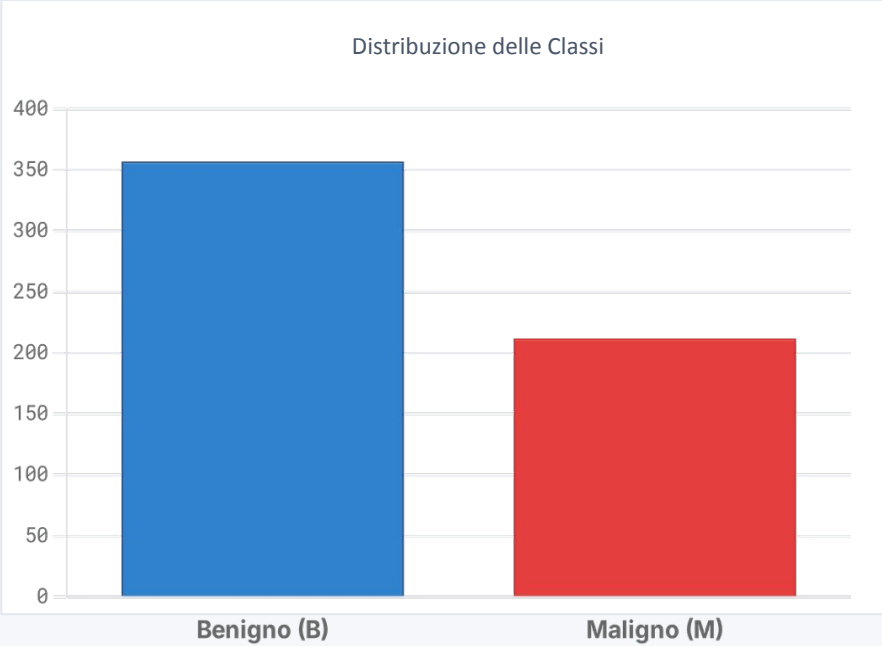

# Pipeline di Sviluppo

1

### Preprocessing

Normalizzazione dei dati per uniformare le scale.

StandardScaler

2

### Data Split

Divisione stratificata per mantenere le proporzioni.

75% Train / 25% Test

3

### Training

Addestramento del modello di regressione logistica.

LogisticRegression (lbfgs)

4

### Valutazione

Misurazione delle performance su dati non visti.

Accuracy, ROC-AUC

# Correlazioni Rivelano Feature Ridondanti

La **heatmap** evidenzia cluster di variabili altamente correlate, indicando ridondanza nei dati.

Variabili come **radius_mean**, **perimeter_mean** e **area_mean** hanno correlazione > 0.99 (rischio multicollinearità).

Feature come **texture_se** e **symmetry_se** mostrano correlazioni più basse, offrendo informazioni indipendenti.

**La selezione delle feature riduce la dimensionalità e migliora la generalizzazione.**

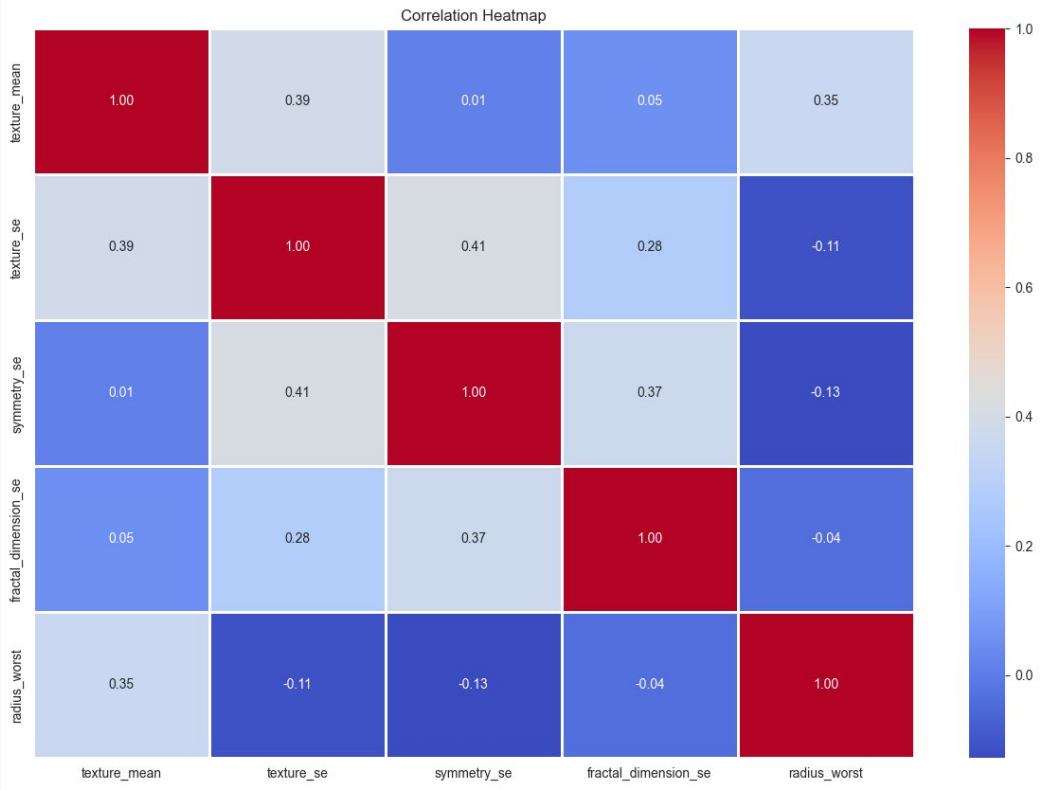

# Importanza delle Variabili

**radius_worst** ha l'impatto maggiore: dimensioni elevate della massa sono il segnale più allarmante.

**texture_mean**: La variazione nella texture cellulare è il secondo fattore più discriminante.

**fractal_dimension_se**: L'irregolarità dei bordi cellulari contribuisce significativamente.

Le variabili **texture_se** e **symmetry_se** hanno peso minore ma affinano la predizione.

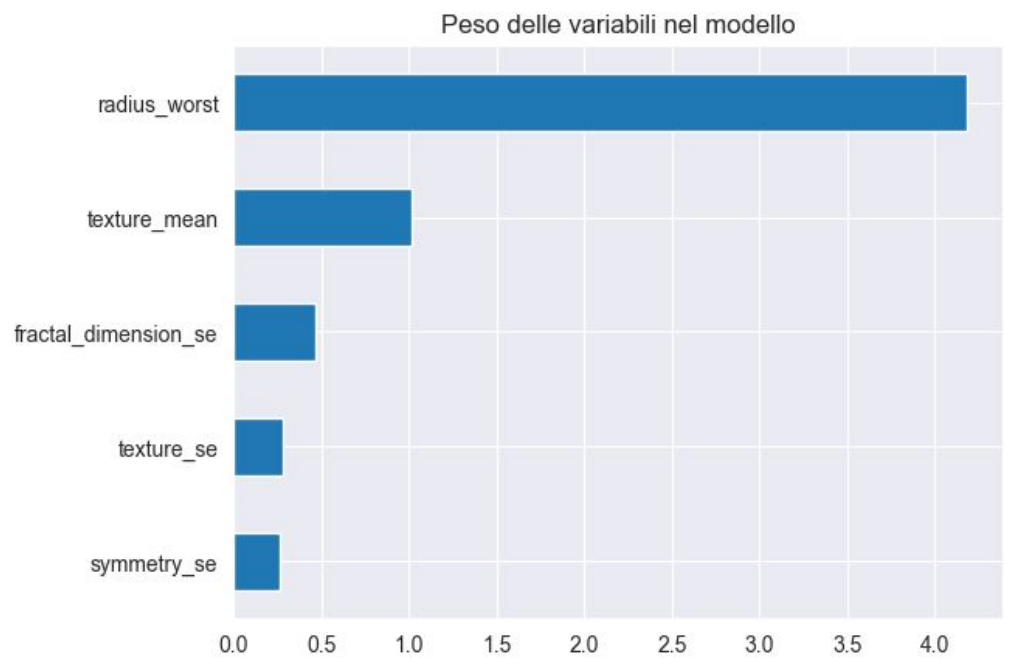

# Distribuzione delle Feature per Diagnosi

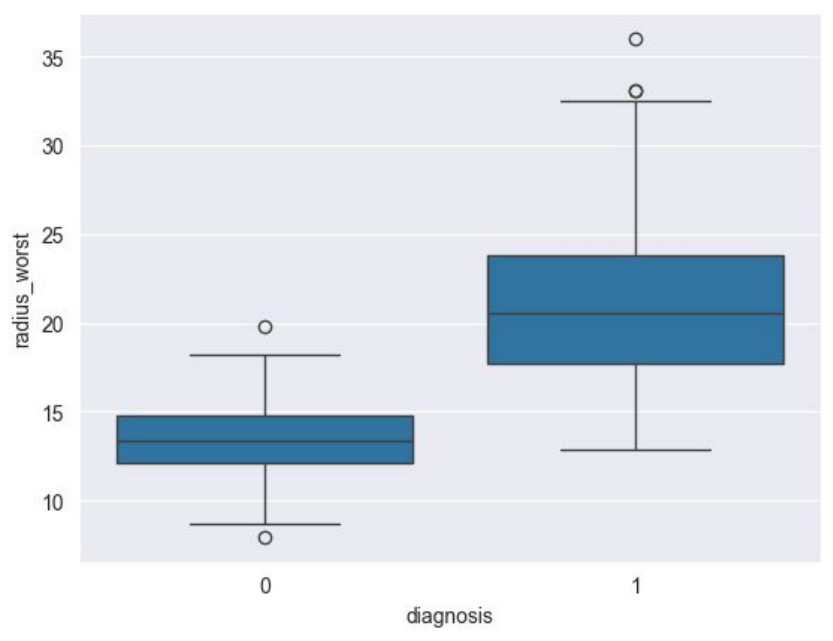


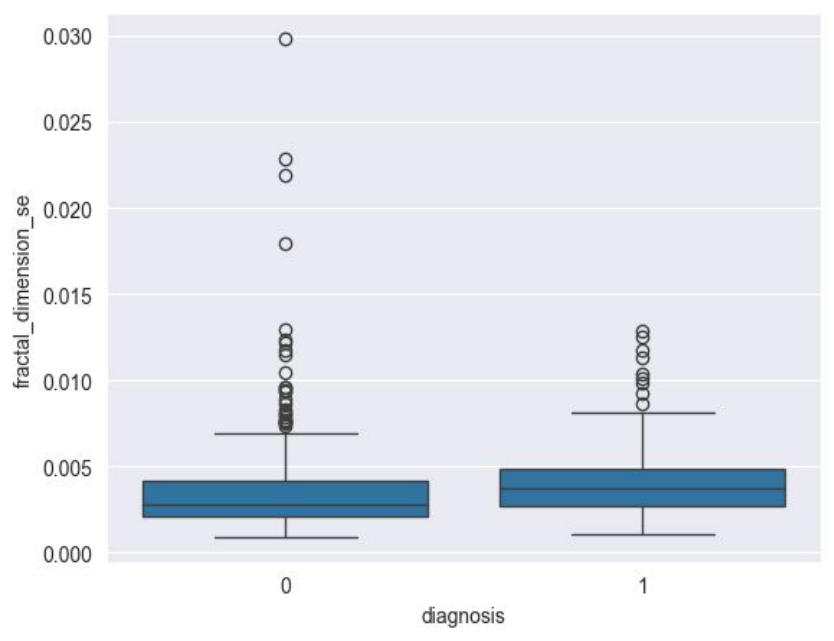


**radius_worst** mostra una netta separazione tra benigni (0) e maligni (1): valori elevati indicano alta probabilità di malignità

**fractal_dimension_se** mostra invece una distribuzione più sovrapposta, confermando il suo peso minore nel modello.

# Dataset Splitting & Model Training

**Obiettivo: classificazione dei tumori (benigno – maligno) attraverso la Logistic Regression**

## Dataset Distribution

| Subset | Proporzione | Obiettivo |
|---|---|---|
| **Training Set** | 75% | Training del modello |
| **Test Set** | 25% | Valutazione della capacità predittiva sulla restante parte dei dati |

## Training Process

Il modello impara la relazione tra le variabili cliniche e le dignosi.
Individua in questo modo I coefficienti della logistic regression per stimare le probabilità di diagnosi.

## Why Split?

Essenziale per evitare l'**overfitting**, valutare le capacità di predizione e assicurare che il modello performi in modo affidabile su dati clinici reali.

# Risultati: Prestazioni del Modello

Accuratezza > 90%: Modello Affidabile per la Diagnosi

| 95% | 95% | 95% | 0.99 |
|---|---|---|---|
| Accuracy(Global Metric) | Precision (Average) | Recall (Average) | AUC-ROC |

Confusion Matrix

| | Pred: Benigno | Pred: Maligno |
|---|---|---|
| Reale: Benigno | 86 True Negative | 3 False Positive |
| Reale: Maligno | 4 False Negative | 50 True Positive |

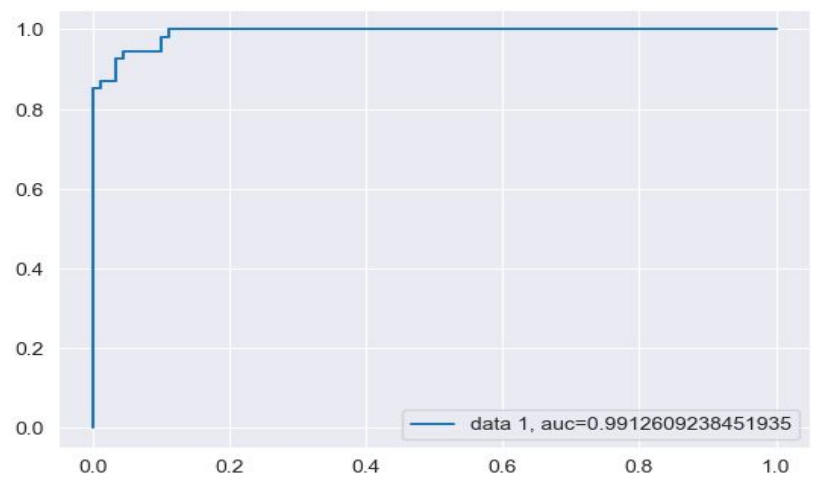

**Accuracy** risponde alla domanda: "In generale, quanto spesso il modello indovina la diagnosi corretta?"

**Precision** risponde alla domanda: "Di tutti quelli indicati come maligni, quanti lo sono davvero?"

**Recall** risponde alla domanda: "Di tutti i maligni reali, quanti ne ha scovati il modello?"

**F1-Score** risponde alla domanda: "Qual è il bilanciamento ottimale tra Precision e Recall?"

**Confusion Matrix**

**Totale Test: 143 casi**

| | Pred: Benigno | Pred: Maligno |
|---|---|---|
| Reale: Benigno | 86 True Negative | 3 False Positive |
| Reale: Maligno | 4 False Negative | 50 True Positive |

# Riepilogo delle Metriche, come ricordarli nel nostro modello?

## ACCURACY

Su 100 pazienti totali che entrano in clinica, quante diagnosi (sia di salute che di malattia) il modello identifica correttamente?
OBBIETIVO: Correttezza Globale.

## PRECISION

Se il modello diagnostica 10 tumori come "Maligni" e 9 lo sono davvero, è preciso.
Evita di spaventare inutilmente pazienti sani.
OBBIETIVO: Ridurre i Falsi Positivi (Falsi Allarmi)

## RECALL

Se ci sono 10 pazienti malati e il modello ne identifica 9, la capacità di "scovarli tutti" è del 90%.
Fondamentale per non ignorare malati reali.
OBBIETIVO: Ridurre falsi Negativi(Omissioni)

## F1- SCORE

Il voto finale di qualità: il modello è eccellente se identifica i pazienti sani (Precision) E non ignora i pazienti malati (Recall).
OBBIETIVO: Bilanciamento tra Precison e Recall (Equilibrio Clinico).

# Come si interpreta la curva Roc?

- **L'asse verticale** rappresenta i successi: quanti tumori maligni abbiamo individuato correttamente.

- **L'asse orizzontale** rappresenta gli errori: quante volte abbiamo scambiato un tumore benigno per maligno.

- **La "perfezione":** Più la curva si spinge verso l'angolo in alto a sinistra, più il modello è preciso. Una linea che taglia il grafico a metà (diagonale) indicherebbe invece un modello che va a "indovinare" a caso, come il lancio di una moneta.

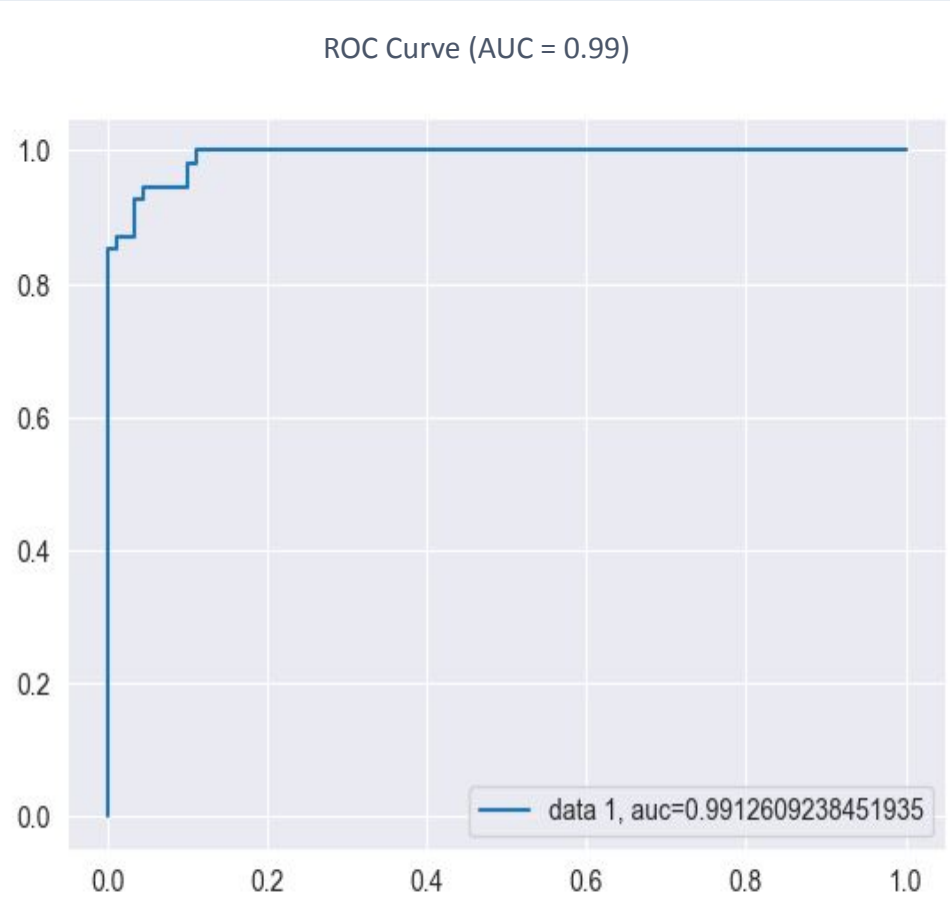

# Conclusioni e Sviluppi Futuri

## Risultati Chiave

- Modello **accurato e interpretabile** con Accuracy > 90% e AUC > 0.99.
- Solo **5 variabili** sufficienti per ottenere un alto potere predittivo.
- Logistic Regression **efficace e trasparente** per dati medici strutturati.

## Sviluppi Futuri

- Sperimentare modelli più complessi
- Applicare tecniche di **cross-validation** per una stima più robusta.
- Integrare il modello in un'**interfaccia clinica** per supporto alla diagnosi.
- Espandere il dataset con più pazienti e **variabili genomiche**.

# Grazie per l'attenzione!

Progetto di Machine Learning – 2026

Carlo C. | Luca R. | Elena L.